Razvoj sustava za 3D lokalizaciju korištenjem UWB tehnologije i EKF filtra

Dokumentacija projekta

29. siječnja 2026.

1 Uvod

Cilj projekta je izgraditi vlastiti "Localization Engine" koji koristi UWB module za precizno praćenje objekta u prostoru.

1.1 Odabir hardvera i drivera

Odabran je modul **DWM3001CDK** koji sadrži moderni dwm3001c UWB modul upakiran u *development kit*. Za programiranje je korišten **ZephyrRTOS**, pri čemu je postojeći sample code prilagođen upotrebi u lokalizacijskom sustavu te je dobiven modified code.

1.2 Razvoj ROS2 drivera

prilagođen upotrebi u lokalizacijskom sustavu te je dobiven ROS2 driver je podijeljen u 3 glavna dijela

1. **Parser:** C++ node za čitanje serial-a s DWM3001CDK tag-a.
2. **Localisation Engine:** Glavna logika sustava koje procesira parsirane inpute i lokalizira objekt u prostoru.
3. **Networking Nodes:** Komunikacija putem MQTT protokola za wireless nadzor i vizualizaciju.

2 Arhitektura sustava

Sustav je zasnovan na asinkronoj komunikaciji između više komponenti, što je prikazano na sljedećem dijagramu:

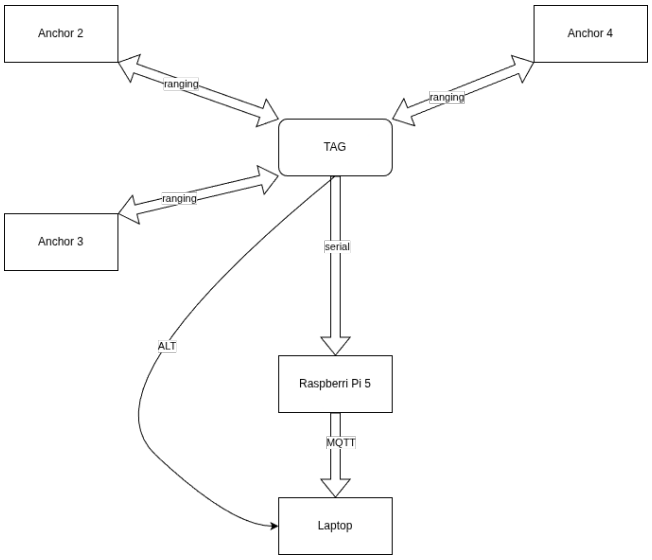

Slika 1: Slika 1 Model sustava

2.1 Opis komponenti

- **Anchors:** Fiksni moduli (DWM3001CDK) koji služe kao responderi i referentne toččke u prostoru.
- **TAG (Značka):** Mobilni modul koji komunicira s achorom radi mjerenja udaljenosti (*ranging*).
- **Raspberry Pi 5:** Služi kao procesorski node koji preko serial-a prikuplja podatke s TAG-a i prosljeđuje ih putem MQTT protokola na laptop na kojemu se vrti vizualizacija.
- **Localisation Engine (Laptop):** Centralno računalo koje vizualizira pozicija TAG.

  *Note: Raspberry Pi 5 se može izostaviti te TAG povezati direktno na laptop što je prikazano strelicom **ALT***

3 Testiranja

Prvo testiranje sustava lokalizacije provedeno je u zajedničkoj učionici mojeg studentskog doma korištenjem tri fiksna *anchora* i jednog mobilnog *TAG-a*. U ovoj konfiguraciji, Raspberry Pi 5 služi kao centralni procesorski čvor koji putem serial-a prikuplja podatke s modula, izvodi algoritam lokalizacije te putem MQTT protokola prosljeđuje podatke na prijenosno računalo radi vizualizacije unutar RVIZ2 okruženja (*rviz2*).

Prvo testiranje je bilo namijenjeno uhodavanju sustava te točnost mjerenja nije bila od presudne važnosti. U ovom testu još je bio korišten jednostavni trilaterizacijski algoritam.

Testiranje je provedeno kretanjem TAG-a između fiksno postavljenih referentnih točaka laganim hodom. Rezultati su pokazali da sustav uspješno određuje lokaciju objekta vrlo rijetko i nepouzdano(posljedica korištenog algoritma) no također je pokazano da je sustav izuzev algoritma lokalizacije u potpunosti stabilan.

Drugo testiranje je provedeno u učionici A111 na FER-u. Korišten je asinkroni EKF te su rezultati bili mnogo bolji od prvog testa. *Input lag* u sustavu se uvelike smanjio, te je preciznost značajno

poboljšana. Također ovo testiranje je pokazalo da je potrebno smisliti bolji način evaluacije preciznosti sustava, drugim riječima potrebno je osmisliti način na koji bi se mjerenja sustava mogla usporediti s *ground truth* u stvarnom vremenu.

U nastavku su prikazane slike hardverske konfiguracije korištene tijekom drugog testiranja:

Slika 2: Konfiguracija Anchora

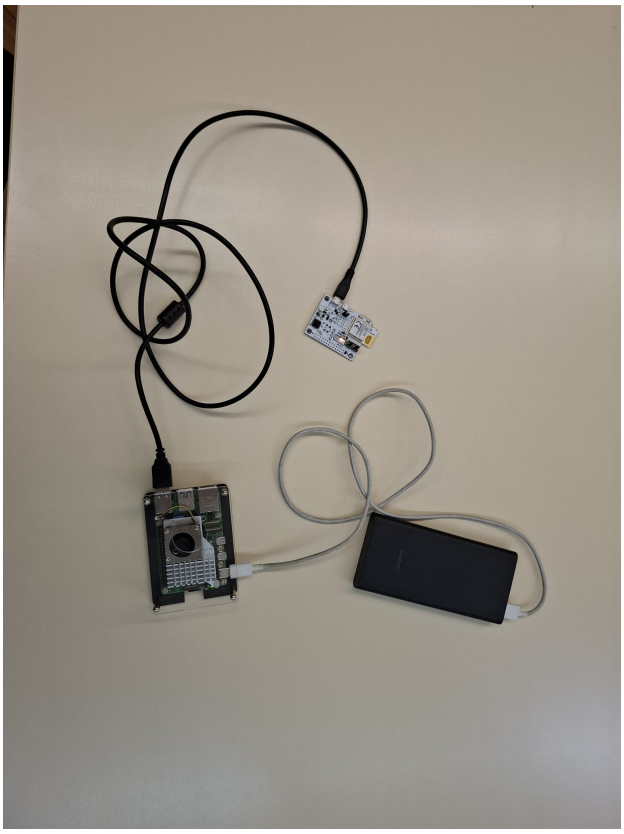

Slika 3: Konfiguracija TAG-a

4 Matematički model: Extended Kalman Filter (EKF)

4.1 Model stanja

Vektor stanja x uključuje 3D poziciju i linearnu brzinu:

$$x = [x_k, y_k, z_k, v_{xk}, v_{yk}, v_{zk}]^T \tag{1}$$

Matrica prijelaza stanja F za model konstantne brzine:

$$F = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \tag{2}$$

4.2 Model mjerenja (Asinkroni/Sekvencijalni)

Budući da mjerenja s anchora dolaze zasebno, koristimo sekvencijalni update. Za anchor i na poziciji (x_i, y_i, z_i), Jakobijan H_i je:

$$H_i = \begin{bmatrix} \frac{x_k - x_i}{d_i} & \frac{y_k - y_i}{d_i} & \frac{z_k - z_i}{d_i} & 0 & 0 & 0 \end{bmatrix} \tag{3}$$

5 Plan za budućnost

Daljnji razvoj fokusirat će se na:

- "Fine-tuning" parametara EKF filtra (Q i R matrice).
- Implementaciju kalibracije točnih pozicija sidara.
- Dodavanje "Ground Truth" sustava za preciznu usporedbu rezultata.