Lokalizacija korištenjem UWB tehnologije temeljena na proširenome Kalmanovom filtru

UWB-Based Localization Using an Extended Kalman Filter

AUTOR

Nikola Horvat

MENTOR

prof. dr. sc. Ivan Marković

NEPOSREDNI MENTOR

univ. mag. ing. el. techn. inf. Vlaho Josip Štironja

FER

Sveučilište u Zagrebu

ZAVRŠNI RAD

TEMA ZAVRŠNOG RADA

Lokalizacija korištenjem UWB tehnologije temeljena na proširenome Kalmanovom filtru

FER
Sveučilište u Zagrebu

Uvod i motivacija

Izazovi lokalizacije i potencijal UWB tehnologije

Ograničenja GNSS sustava

Nepouzdanost u zatvorenom: Signal se blokira ili drastično slabi unutar zgrada.

Ograničena preciznost: Standardni sustavi ne pružaju potrebnu centimetarsku točnost za robotiku.

Zašto UWB?

Visoka vremenska rezolucija: Omogućuje iznimno precizno mjerenje vremena leta (ToF) i udaljenosti.

Propagacija kroz prepreke: Sposobnost prolaska signala kroz zidove i objekte u kompleksnim okruženjima.

Kombinacija **UWB tehnologije** i **Proširenog Kalmanovog filtra** osigurava robusnu lokalizaciju u realnom vremenu.

Ciljevi projekta

Glavne ciljevi razvoja "Localization Engine" sustava

Lokalizacija i EKF

Razvoj robusnog sustava za procjenu položaja u stvarnom vremenu primjenom **Proširenog Kalmanovog filtra (EKF)** na UWB mjerenja.

Online kalibracija sidara

Istraživanje mogućnosti **istovremene kalibracije** sidara uključivanjem njihovih koordinata u vektor stanja filtra radi eliminacije ručne pripreme.

ROS2 & Raspberry Pi

Implementacija na **Raspberry Pi 5** platformi unutar **ROS2** okruženja za modularnu obradu podataka i drivere.

Evaluacija točnosti

Vizualizacija trajektorije u **RViz2** te kvantitativna usporedba točnosti između sustava s poznatom i nepoznatom pozicijom sidara.

KONAČNI CILJ: **Postizanje centimentarne preciznosti**

ARHITEKTURA SUSTAVA

Modularna struktura i protok podataka

Sidra (Anchors)

DWM3001CDK moduli fiksirani na poznatim ili nepoznatim pozicijama (za online kalibraciju).

Mobilni TAG

DWM3001CDK modul koji komunicira s ankorima radi mjerenja udaljenosti (ranging).

Raspberry Pi 5

Služi kao procesorski čvor. Prikuplja podatke s TAG-a putem serijske veze i prosljeđuje ih putem MQTT protokola.

Localization Engine

Glavna logika na laptopu koja obrađuje podatke, izvodi EKF i vizualizira rezultate u RViz2.

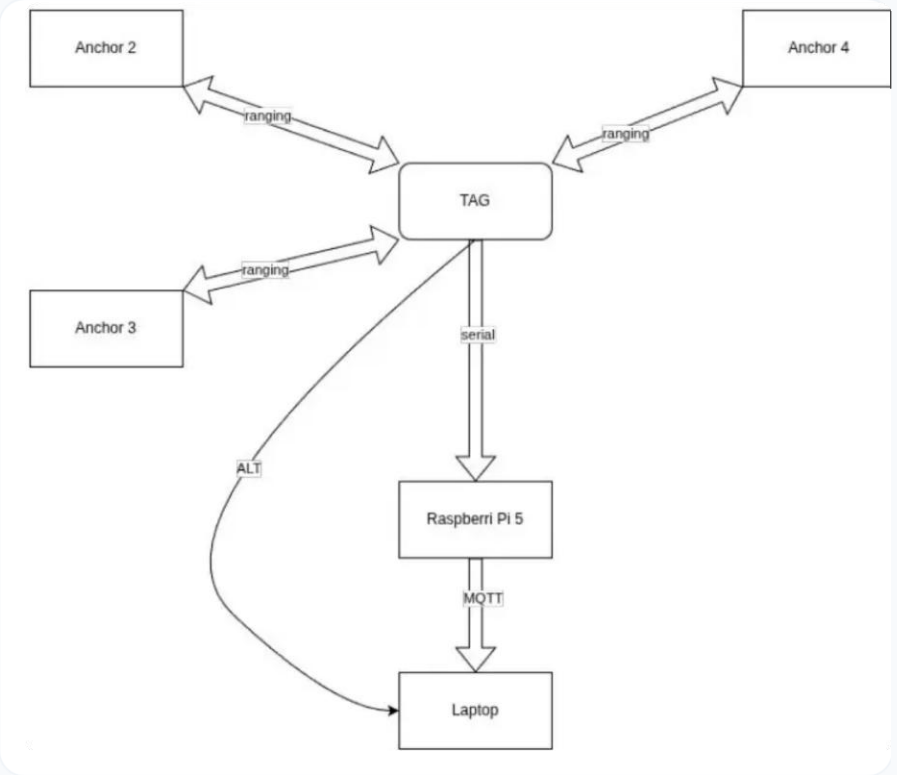

SLIKA 1: MODEL SUSTAVA

Razvoj softvera i ROS2 drivera

SOFTWARE STACK

Hardver: DWM3001CDK (UWB Modul) **Firmware:** Zephyr RTOS (prilagođeni primjerni kod)

Parser (C++ Node)

Čitanje sirovih serijskih podataka s TAG modula. Transformacija u strukturirani format i objava kao ROS2 poruke za daljnju obradu.

Localization Engine

Glavna logika sustava. Implementacija asinkronog EKF algoritma za procjenu 3D položaja i brzine objekta u stvarnom vremenu.

Networking Nodes

Komunikacijski most temeljen na MQTT protokolu. Omogućuje bežični nadzor i odvajanje vizualizacije od procesa lokalizacije.

KONCEPTUALNA SKICA SUSTAVA

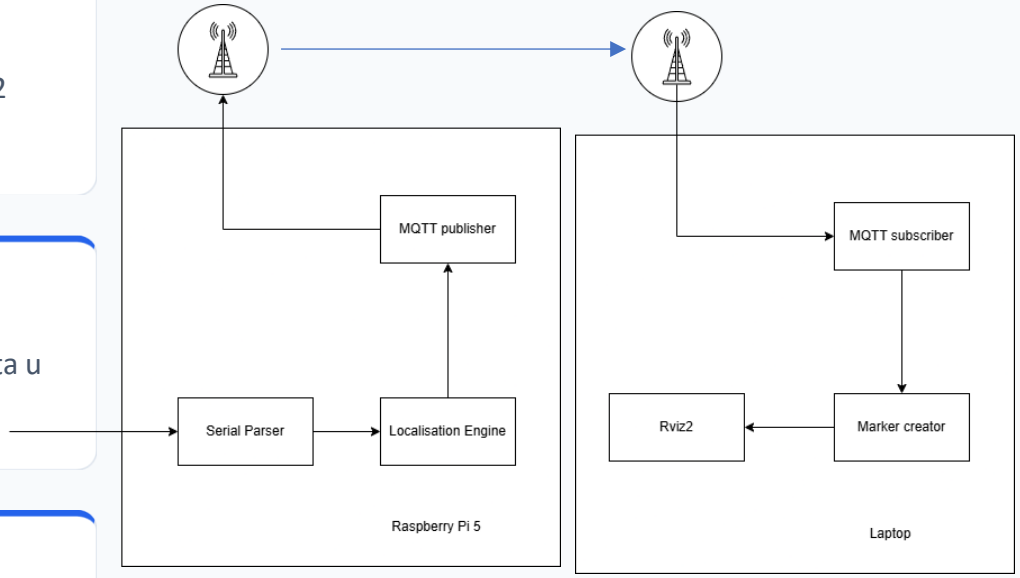

MODULARNOST UČINKOVITOST SKALABILNOST

Zašto ROS2?

Prednosti ROS2 ekosustava za ovaj projekt

Modularnost

Svaka komponenta sustava (parser, EKF, networking) implementirana je kao **zasebni ROS2 čvor**. Čvorovi se mogu razvijati, testirati i zamjenjivati neovisno — bez utjecaja na ostatak sustava.

C++/Python | Topics /Remaps

Launch datoteke

Cijeli sustav — parser, EKF jezgra, MQTT bridge i vizualizacija — pokreće se **jednom naredbom** putem ROS2 launch datoteke. Parametri se konfiguriraju centralno bez izmjene koda.

ros2 launch | YAML config

RViz2 — gotov alat

Umjesto razvoja vlastitog vizualizacijskog okruženja, koristi se **RViz2** — moćan 3D alat ugrađen u ROS2. Trajektorija TAG-a, pozicije sidara i stanje filtra vidljivi su u realnom vremenu bez ijednog retka GUI koda.

3D Vizualizacija | Real-time

ROS2 eliminira potrebu za razvojem infrastrukture — fokus ostaje na **algoritmu lokalizacije**.

Matematički model: EKF (1. dio)

$$x = [x_k, y_k, z_k, v_{xk}, v_{yk}, v_{zk}]^T$$

State space vector

$$h_i(\hat{x}_k^-) = \sqrt{(x_k - x_i)^2 + (y_k - y_i)^2 + (z_k - z_i)^2}$$

Meassurement function

$$F = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

Transition matrix

$$H = \begin{bmatrix} \frac{\partial h_1}{\partial x_k} & \frac{\partial h_1}{\partial y_k} & \frac{\partial h_1}{\partial z_k} & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial h_n}{\partial x_k} & \frac{\partial h_n}{\partial y_k} & \frac{\partial h_n}{\partial z_k} & 0 & 0 & 0 \end{bmatrix}$$

$$\frac{\partial h_i}{\partial x_k} = \frac{x_k - x_i}{h_i(\hat{x}_k^-)}, \quad \frac{\partial h_i}{\partial y_k} = \frac{y_k - y_i}{h_i(\hat{x}_k^-)}, \quad \frac{\partial h_i}{\partial z_k} = \frac{z_k - z_i}{h_i(\hat{x}_k^-)}$$

Jacobian & derivation

Matematički model: EKF (2. dio)

MODEL MJERENJA I LINEARIZACIJA

Extended Kalman Filter Logic

$$\hat{x}_k^- = F\hat{x}_{k-1}$$

$$P_k^- = FP_{k-1}F^T + Q$$

Prediction step

$$e_k = z_k - h(\hat{x}_k^-) \quad \text{(Error)}$$

$$S_k = HP_k^- H^T + R \quad \text{(Error Covariance)}$$

$$K_k = P_k^- H^T S_k^{-1} \quad \text{(Kalman Gain)}$$

$$\hat{x}_k = \hat{x}_k^- + K_k e_k \quad \text{(Updated Estimate)}$$

$$P_k = (I - K_k H)P_k^- \quad \text{(Updated Covariance)}$$

Correction step

Asinkroni Update

Mjerenja s pojedinih sidara ne dolaze istovremeno. Sustav koristi **sekvencijalni update**:

Obrada svakog mjerenja čim postane dostupno

Smanjenje latencije (Input Lag)

Veća fleksibilnost u asinkronim mrežama

Testiranje i evaluacija

Faza 2: Napredna evaluacija u učionici A111 (FER)

2. Test: FER — UČIONICA A111

Evaluacija asinkronog EKF filtera

Algoritam

Asinkroni Prošireni Kalmanov filter (EKF) — svako mjerenje obrađuje se čim zasebno

Postav

3 UWB sidra (DWM3001CDK) raspoređena u učionici A111 na FER-u. Mobilni TAG na Raspberry Pi 5.

Cilj

Procjena poboljšanja preciznosti i odzivnosti u odnosu na jednostavnu trilateraciju.

KLJUČNI REZULTATI

Smanjen **input lag** zahvaljujući sekvencijalnom updateu

Visoka **robusnost** i stabilnost praćenja u stvarnom okruženju

Zaključak evaluacije

Hardverska konfiguracija testiranja

Eksperimentalni postav u učionici A111 (FER)

1. Konfiguracija Sidara (Anchors)

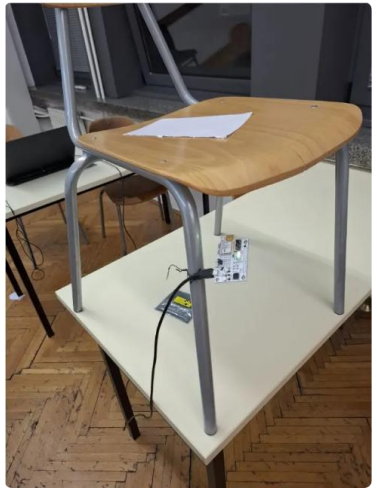

Moduli: DWM3001CDK fiksirani na strateškim pozicijama.

Montaža: Postavljeni na stabilne nosače (stolice/stolovi) radi optimalne pokrivenosti.

Uloga: Služe kao referentne točke (responderi) za mjerenje udaljenosti.

2. Konfiguracija Značke (TAG)

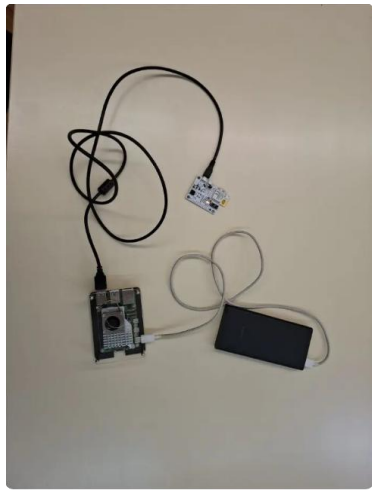

Centralni čvor: Raspberry Pi 5 napajan putem prijenosne baterije.

Mobilna jedinica: UWB TAG modul povezan serijskom vezom na Raspberry Pi.

Obrada: Lokalno izvođenje algoritma lokalizacije i prijenos putem MQTT-a.

Budući razvoj i poboljšanja

Strategija za optimizaciju točnosti i skalabilnosti sustava

Optimizacija EKF-a

Fino podešavanje **Q** (procesni šum) i **R** (mjerni šum) matrica.

Optimiziranje implementacije EKF-a

Napredna kalibracija

Proširenje vektora stanja koordinatama sidara za **automatsku online kalibraciju**.

Ground Truth & Evaluacija

Implementacija **Ground Truth** sustava za preciznu referentnu validaciju trajektorije.

Kvantitativna usporedba EKF-a s referentnim mjerenjima za objektivnu evaluaciju točnosti.

Cilj: Razvoj potpuno autonomnog sustava s centimetarskom točnošću s minimalnom ljudskom konfiguracijom.

ROADMAP 2026

Hvala na pažnji!

AUTOR
Nikola Horvat

MENTOR
prof. dr. sc. Ivan Marković

NEPOSREDNI MENTOR
univ. mag. ing. el. techn. inf. Vlaho Josip Štironja

NH

Nikola Horvat

@ nh55636@fer.hr

in linkedin.com/in/nikola-horvat-111968295

FER — Fakultet elektrotehnike i računarstva, Sveučilište u Zagrebu